

24 de setembro de 2023

# **ANÁLISE FATORIAL EXPLORATÓRIA**

ME731 - ANÁLISE MULTIVARIADA

Ana Julia Cunha e Silva - RA: 236038

## Súmario

|   |           |
|---|-----------|
| <b>Lista de Tabelas</b>                                   | <b>1</b>  |
| <b>Lista de Figuras</b>                                   | <b>1</b>  |
| <b>1 Introdução</b>                                       | <b>2</b>  |
| <b>2 Análise Fatorial: Teoria</b>                         | <b>3</b>  |
| 2.1 Modelo Fatorial Ortogonal                             | 3         |
| 2.2 Estimacão e Máxima Verossimilhança                    | 4         |
| 2.3 Rotação de Fatores                                    | 4         |
| <b>3 Vantagens</b>  | <b>5</b>  |
| <b>4 Desvantagens</b>                                     | <b>5</b>  |
| <b>5 Análise Fatorial Exploratória: Aplicação Prática</b> | <b>6</b>  |
| 5.1 Testes  | 7         |
| 5.2 Modelos Fatoriais                                     | 7         |
| 5.3 Conclusão Prática                                     | 9         |
| <b>6 Conclusão</b>  | <b>9</b>  |
| <b>7 Referências Bibliográficas</b>                       | <b>10</b> |

## Lista de Tabelas

|   |  |   |
|---|--|---|
| 1 | Estatísticas Básicas dos Dados         | 6 |
| 2 | Teste KMO - Resultados Específicos     | 7 |
| 3 | Valores dos Autovalores para 6 Fatores | 7 |
| 4 | Cargas Fatoriais Com e Sem Rotação     | 8 |

## Lista de Figuras

|   |  |   |
|---|--|---|
| 1 | Exemplo Visual de uma Rotação Fatorial | 5 |
| 2 | Correlograma dos Dados                 | 6 |
| 3 | Gráfico Scree                          | 7 |
| 4 | Pontuação dos Fatores - Sem Rotação    | 8 |
| 5 | Fatores - Sem Rotação                  | 8 |
| 6 | Pontuação dos Fatores - Com Rotação    | 9 |
| 7 | Fatores - Com Rotação                  | 9 |

# 1 Introdução

Este relatório tem como propósito apresentar, com certo nível de detalhe teórico a técnica multivariada Análise Fatorial Exploratória. Além de apresentar, este relatório irá fazer uma abordagem prática exemplificada com um banco de dados e o software RStudio, além de descrever e discutir vantagens e desvantagens da técnica em questão. A estrutura do documento se resume em, análise teórica, análise prática, discussão sobre as vantagens e desvantagens do método e por fim conclusões sobre os resultados da análise prática e conclusão geral do método.

No Rstudio foram utilizados os pacotes *psych* e *corrplot* para fazer a análise prática, além do banco de dados que consiste na tabela 1.9 de [1] porém disponibilizado no google drive, sendo assim necessário acesso a internet para rodar o arquivo da linguagem r. Todos os valores utilizados para fazer as tabelas da parte prática foram arredondados com 2 casas decimais.

## 2 Análise Fatorial: Teoria

Por volta do começo do século XX, Karl Pearson, Charles Spearman e outros interessados em definir e medir inteligência deram origem à análise fatorial, conforme dito em [1]. Desde então, a técnica continuou sendo aplicada nas áreas de ciências humanas e em algumas outras, para medir variáveis não observáveis.

As variáveis não observáveis, ou variáveis latentes, são aquelas que não podemos mensurar diretamente, precisamos observar outras variáveis para então relacioná-las, por meio de um modelo matemático (um *modelo linear*), a ponto que seja possível inferir a variável latente de interesse. Por exemplo, a personalidade é uma variável que não conseguimos observar, em [2] temos o exemplo do nível socioeconômico. "Para mensurá-lo, fazemos perguntas sobre questões como ocupação e escolaridade dos pais, bens domésticos, bens culturais e recursos educacionais da casa" disseram MATOS e RODRIGUES em [2]. Essencialmente, um fator (variável latente) é uma combinação linear de algumas variáveis observadas, que não é possível ser medida direto. Será usado o termo fator para se referir às essas variáveis não observáveis.

Existem algumas métricas importantes relacionadas aos fatores, uma delas é a *Carga Fatorial*. A carga fatorial de uma variável nada mais é do que correlação dessa variável com os fatores de interesse, sendo que para fatores diferentes ela provavelmente terá valores diferentes. Como é a correlação da variável com o fator, se a carga for positiva a variável estará positivamente correlacionada ao fator e idem para o caso de correlação negativo, assim como explicado em [2]. Como dito anteriormente, um fator pode ser definido por um *modelo linear*, sendo que para isso usamos as cargas fatoriais que chamaremos de  $\lambda_i$  a carga fatorial da variável no  $i$ -ésimo fator ( $X_i$ ).

Além da carga fatorial, ainda tem outra métrica interessante e importante na análise fatorial, o *Escore Fatorial*, que resumidamente um escore fatorial é a estimativa de um fator. Abordando por cima, em [2] é citado duas formas de calcular o escore, uma fazendo a média ponderada das variáveis observáveis com os pesos sendo as cargas fatoriais respectivas. A outra forma produz escores com a distribuição normal padrão ( $N(0, 1)$ ).

Existem dois tipos de análise fatorial, a exploratória e a confirmatória. A Análise Fatorial Exploratória é usada quando não se tem noção de quantidade dos fatores, pouco conhecimento dos dados e não tem hipóteses iniciais, assim ela é usada para formular essas hipóteses e encontrar os fatores.

Já a Análise Fatorial Confirmatória é usada quando já temos as hipóteses iniciais e bom conhecimento do banco de dados, portanto, assim como o nome mesmo já diz, esse método busca confirmar as hipóteses. O segundo método é bem mais complicado e rígido que o primeiro, visto que seu propósito é confirmar/validar hipóteses, é preciso ter muito conhecimento sobre os dados, como foram colhidos e a quantidade de fatores existentes. Por isso nesse trabalho, exploraremos a Análise Fatorial Exploratória.

### 2.1 Modelo Fatorial Ortogonal

Seguindo [4], seja  $\mathbf{X} = (x_1, x_2, \dots, x_p)'$  um vetor ( $p \times 1$ ) com as  $p$ -variáveis observáveis  $x_i$ ,  $i = 1, \dots, p$  e com  $E(\mathbf{X}) = \mu$  e matriz de covariâncias  $\mathbf{Var}(\mathbf{X}) = \Sigma$ ,  $\mathbf{F} = (f_1, f_2, \dots, f_k)'$  o vetor ( $k \times 1$ ) dos  $f_j$ ,  $j = 1, \dots, k$  fatores comuns com  $k < p$ ,  $\mathbf{U}$  é o vetor de fatores únicos e  $\mathbf{Q}$  a matriz ( $p \times k$ ) de cargas fatoriais, onde o elemento  $q_{ij}$  a carga fatorial da  $i$ -ésima variável no  $j$ -ésimo fator. Portanto o modelo fatorial ortogonal é:

$$x_i = \sum_{j=1}^k q_{ij} f_j + u_i + \mu_i \quad (1)$$

Em notação matricial temos:

$$\mathbf{X} = \mathbf{U} + \mathbf{QF} + \mu \quad (2)$$

Com as seguintes suposições:

- (i)  $\mu_i$  é a média da  $i$ -ésima variável
- (ii)  $\mathbf{F}$  e  $\mathbf{U}$  são vetores aleatórios, não observáveis e não-correlacionados
- (iii)  $E(\mathbf{F}) = 0$ ,  $Var(\mathbf{F}) = \mathbf{I}_k$ , onde  $\mathbf{I}_k$  é a matriz identidade ( $k \times k$ )
- (iv)  $Cov(u_l, u_g) = 0$ ,  $l \neq g$ ,  $Cov(\mathbf{U}, \mathbf{F}) = 0$  e  $Cov(\mu, \mathbf{F}) = 0$

$$(v) \text{Var}(\mathbf{U}) = \Psi = \begin{bmatrix} \psi_{11} & & \\ & \ddots & \\ & & \psi_{pp} \end{bmatrix}$$

Além disso, da equação (1) e das suposições acima, conseguimos chegar em:

$$\text{Var}(x_i) = \sum_{j=1}^k q_{ij}^2 + \psi_{ii} \quad (3)$$

Onde  $h_i^2 = \sum_{j=1}^k q_{ij}^2$  é chamado de comunalidade e  $\psi_{ii}$  é a variância específica.

Além disso o modelo fatorial ortogonal tem algumas propriedades relacionadas a variância de  $\mathbf{X}$  e covariância das matrizes:

- $\text{Var}(\mathbf{X}) = \Sigma = \mathbf{Q}\mathbf{Q}' + \Psi$ , onde  $\Psi$  foi definido na suposição (v)
- $\text{Cov}(\mathbf{X}, \mathbf{F}) = \text{Cov}(\mathbf{U} + \mathbf{Q}\mathbf{F} + \mu, \mathbf{F})$   
Como  $\mathbf{Q}$  é constante, temos:  
 $\Rightarrow \text{Cov}(\mathbf{U}, \mathbf{F}) + \text{Cov}(\mu, \mathbf{F}) + \mathbf{Q}\text{Cov}(\mathbf{F}, \mathbf{F}) = 0 + 0 + \mathbf{Q}\text{Var}(\mathbf{F}) = \mathbf{Q}\mathbf{I}_k = \mathbf{Q}$

## 2.2 Estimação e Máxima Verossimilhança

Na estimação, do modelo fatorial, temos interesse em estimar duas matrizes, a matriz com as cargas fatoriais( $\mathbf{Q}$ ) e a matriz diagonal( $\Psi$ ) com a variância específica, levando em consideração principalmente a propriedade  $\text{Var}(\mathbf{X}) = \mathbf{Q}\mathbf{Q}' + \Psi$  e definindo  $\mathbf{S} = \hat{\mathbf{Q}}\hat{\mathbf{Q}}' + \hat{\Psi}$ , assim estaremos estimando  $\Sigma$  por meio de  $\mathbf{S}$ . Existem várias formas de estimar esses valores, uma delas é por Análise de Componentes Principais e outra, que será abordada, é por meio da *máxima verossimilhança*.

Para estimação das cargas fatoriais( $\mathbf{Q}$ ) e da variância dos fatores únicos( $\Psi$ ) a notação será baseada em [4] e  $\text{tr}()$  corresponde ao traço da matriz dentro do parentêses. Se  $\mathbf{X} \sim N_p(\mu, \Sigma)$ , onde  $N_p$  é uma normal  $p$ -variada, conseguimos estimar  $\hat{\mathbf{Q}}$  e  $\hat{\Psi}$  pelo método de máxima verossimilhança. Como  $\mu = \bar{\mathbf{X}}$ , sendo  $\bar{\mathbf{X}}$  a média amostral e a matriz inversa de  $\Sigma = \sigma$ , temos que a *log-verossimilhança* pode ser definida por:

$$l(\mathbf{X}; \Sigma) = -\frac{n}{2}[\log|2\pi \Sigma| + \text{tr}(\sigma\mathbf{S})] \quad (4)$$

Assim, substituindo  $\sigma = (\mathbf{Q}\mathbf{Q}' + \Psi)^{-1}$  e  $\Sigma = \mathbf{Q}\mathbf{Q}' + \Psi$  temos que a *log-verossimilhança* é proporcional e por sua vez pode ser definida por:

$$l(\mathbf{X}; \mathbf{Q}, \Psi) = -\frac{n}{2}[\log|2\pi(\mathbf{Q}\mathbf{Q}' + \Psi)| + \text{tr}((\mathbf{Q}\mathbf{Q}' + \Psi)^{-1}\mathbf{S})] \quad (5)$$

## 2.3 Rotação de Fatores

Para interpretar os fatores, é possível fazer gráficos de pontos, onde a quantidade de fatores é a quantidade de eixos então se 2 fatores, teremos uma visão em  $\mathbb{R}^2$ , para  $k$ -fatores teremos que visualizar em  $\mathbb{R}^k$ . Com isso a visão gráfica para mais de 2 fatores começa a ficar complicada. Entretanto para 2 fatores, podemos rotaciona-los até termos uma visualização melhor, pois nem sempre a posição cartesiana é a melhor para visualizar os fatores. Abaixo um exemplo de como rotacionar os fatores pode auxiliar na visualização.




Figura 1: Exemplo Visual de uma Rotação Fatorial

Trabalhando com o caso de 2 fatores, uma das técnicas de rotação possível e explicada em [4] é a *Varimax*, que busca simplificar a visualização dos fatores encontrando o  $\theta$  que maximize a variância dos quadrados das cargas em cada coluna da matriz de cargas rotacionada ( $\hat{Q}^*$ ) que será abordada abaixo.

Assim, seja  $G(\theta)$  a matriz de rotação horária com ângulo  $\theta$ ,  $G(\theta) = \begin{bmatrix} \cos(\theta) & \sin(\theta) \\ -\sin(\theta) & \cos(\theta) \end{bmatrix}$

A matriz de cargas fatoriais rotacionadas é dada por  $\hat{Q}^* = \hat{Q}G(\theta)$ .

Por fim, para escolher qual o melhor  $\theta$  para aplicar a técnica, usamos a seguinte formula e maximizamos ela, então encontraremos  $\theta$  ideal:

$$\frac{1}{p} \sum_{j=1}^k \left[ \sum_{i=1}^p \left( \frac{\hat{q}_{ij}^*}{\hat{h}_i^*} \right)^4 - \left( \frac{1}{p} \sum_{j=1}^p \left( \frac{\hat{q}_{ij}^*}{\hat{h}_i^*} \right)^2 \right)^2 \right] \quad (6)$$

Onde  $\frac{\hat{q}_{ij}^*}{\hat{h}_i^*}$  é a estimativa de  $q_{ij}^*$  que é a carga fatorial rotacionada da  $i$ -ésima variável no  $j$ -ésimo fator.

### 3 Vantagens

Uma das vantagens mais importantes da análise fatorial é a **redução da dimensionalidade**, onde reduzimos as várias variáveis em poucos fatores **simplificando o estudo estatístico**.

Na análise fatorial, as variáveis são explicadas pelos fatores, sendo essa característica o que podemos chamar de **representatividade dos dados**. Algo que não ocorre na análise de componentes principais, onde as variáveis explicam os componentes, sendo assim não é possível explicar que tal comportamento de tal variável ocorre por causa do componente, mas é possível falar que a variável tal tem o respectivo comportamento por causa do fator na análise fatorial.

### 4 Desvantagens

Uma grande desvantagem do método é o **tamanho do banco de dados**, normalmente recomenda-se ter no mínimo uma quantidade de dados 5 vezes maior que a quantidade de variáveis no banco, sendo assim o método precisa de muitos dados para ser bem utilizado.

A **dificuldade mais elevada**, tanto matemática quanto computacional, para aplicação do método em relação à análise de componentes principais.

O modelo é muito sensível a mudanças na rotação, podendo se tornar uma desvantagem pois dependendo da rotação feita a interpretação pode variar bastante. Sendo assim a **interpretação** é um tanto quanto **subjetiva** e facilmente influenciável.

## 5 Análise Fatorial Exploratória: Aplicação Prática

O banco de dados utilizado é a tabela 1.9 de [1], que conta com os recordes das provas de corrida na modalidade feminina de 55 países diferentes. Sendo assim, o banco conta com 55 observações, que apesar de não ser o ideal para a aplicação do método, ainda é válido e 8 variáveis sendo elas:

- **COUNTRY**: O país em questão.
- **X100m**: Recorde na prova de 100 metros em segundos.
- **X200m**: Recorde na prova de 200 metros em segundos.
- **X400m**: Recorde na prova de 400 metros em segundos.
- **X800m**: Recorde na prova de 800 metros em minutos.
- **X1500m**: Recorde na prova de 1500 metros em minutos.
- **X3000m**: Recorde na prova de 3000 metros em minutos.
- **Maratona**: Recorde na prova de maratona em minutos.

Para a análise trabalharemos com todas as variáveis exceto **COUNTRY**, pois é a única variável que não é numérica. Começando fazendo uma breve análise das estatísticas básicas encontramos os seguintes dados:

Tabela 1: Estatísticas Básicas dos Dados

| Variável | Média  | DesvPadrão | Mínimo | Máximo |
|----------|--------|------------|--------|--------|
| X100m    | 11,62  | 0,45       | 10,79  | 12,90  |
| X200m    | 23,58  | 1,15       | 21,52  | 27,10  |
| X400m    | 53,61  | 2,99       | 47,99  | 63,60  |
| X800m    | 2,08   | 0,11       | 1,89   | 2,33   |
| X1500m   | 4,40   | 0,40       | 3,87   | 5,81   |
| X3000m   | 9,36   | 1,11       | 3,92   | 13,04  |
| Maratona | 173,25 | 30,46      | 142,72 | 306,00 |

Na tabela acima nota-se que os valores médios das provas mais curtas(100, 200 e 400 metros) estão com valores muito maiores do que as provas mais longas, isso porquê a unidade de medida é diferente. Enquanto nas primeiras provas a medição é em segundos, as demais provas tem medição em minutos.

Pelo correlograma abaixo não conseguimos encontrar nenhum padrão ou tirar qualquer conclusão muito mais profunda do que a correlação entre as variáveis é estritamente positiva. Logo para análises mais profundas faremos o teste de adequação *Kaiser-Meyer-Olkin(KMO)* e o teste de esfericidade de *Bartlett* para confirmar a necessidade de uma análise fatorial.




Figura 2: Correlograma dos Dados

## 5.1 Testes

O teste de Bartlett tem como hipótese nula a matriz de correlação dos dados ser igual a matriz identidade, portanto se o p-valor for muito baixo, poderemos rejeitar a hipótese nula e teremos uma indicação de que seja recomendável fazer uma análise fatorial nos dados. Ao aplicar o teste, obtivemos um p-valor da ordem de  $10^{-54}$ , sendo assim muito pequeno ( $4,43 \cdot 10^{-54}$  mais precisamente) e definindo  $p < 0,05$ , podemos rejeitar a hipótese nula.

Por fim, para confirmar que o método utilizado deve ser a análise fatorial, faremos o teste KMO. Esse teste tem como propósito checar se a análise fatorial é apropriada ou não, para isso ele calcula dois tipos de resposta, o primeiro tipo é o valor global chamado de *Overall MSA* que representa todas as variáveis dos dados, o segundo tipo é o valor específico de cada variável chamado de *MSA for each item*. A seguir os valores específicos (MSA for each item) do teste KMO:

Tabela 2: Teste KMO - Resultados Específicos

| Valor Específico |       |       |       |        |        |          |
|------------------|-------|-------|-------|--------|--------|----------|
| X100m            | X200m | X400m | X800m | X1500m | X3000m | Maratona |
| 0,85             | 0,85  | 0,90  | 0,86  | 0,95   | 0,94   | 0,92     |

O resultado global foi *Overall MSA* = 0,89 sendo assim, com base no padrão escolhido temos mais uma evidência de que esses dados são recomendados para uma análise fatorial, visto que todos os valores são próximos de 1,0 e maiores que 0,8 o que supera o valor mínimo (0,7) recomendado no padrão. Foi escolhido seguir o padrão de [2] onde os valores (tanto global quanto específicos) recomendam a análise fatorial quando são maiores que 0,7 e não recomendam quando são menores que 0,5.

## 5.2 Modelos Fatoriais

Para descobrir quantos fatores seriam necessários, aplicou-se a função de componentes principais usando a matriz de correlações invés da matriz de covariâncias, para poder se adaptar a análise com 6 fatores e sem rotação, apenas para conseguir plotar o scree plot (gráfico scree).




Figura 3: Gráfico Scree

Tabela 3: Valores dos Autovalores para 6 Fatores

| Valor 1 | Valor 2 | Valor 3 | Valor 4 | Valor 5 | Valor 6 | Valor 7 |
|---------|---------|---------|---------|---------|---------|---------|
| 5.07    | 0,60    | 0,44    | 0,37    | 0,27    | 0,14    | 0,11    |

Pela regra de Kaiser escolhemos a quantidade de fatores equivalente a quantidade de autovalores com valor maior que 1, entretanto se fisessemos isso para estes dados teríamos apenas um fator. Entretanto afim de mostrar como o método funciona com mais de um fator, usaremos dois, até porquê os dois primeiros fatores explicam



$\frac{5,067}{7} \cdot 100\% = 72,39\%$  e  $\frac{0,086}{7} \cdot 100\% = 1,23\%$  dos dados separadamente, juntos explicam pouco mais de 80% dos dados. O cálculo do percentual que cada fator explica dos dados é calculado pela razão entre o valor do autovalor pela quantidade de variáveis no modelo.

Com a quantidade de fatores definida, foi utilizada a função própria para análise fatorial no R para enfim serem calculadas as cargas fatoriais e finalizar o estudo.

Foram feitos dois modelos, o primeiro sem nenhum método de rotação e o segundo com o método *varimax*. Considere **MR1** o Fator 1 e **MR2** o Fator 2.

Tabela 4: Cargas Fatoriais Com e Sem Rotação

| Sem Rotação |         |        | Com Rotação |         |        |
|-------------|---------|--------|-------------|---------|--------|
| Variável    | Fator 1 | Fator2 | Variável    | Fator 1 | Fator2 |
| X100m       | 0,886   | -0,298 | X100m       | 0,470   | 0,808  |
| X200m       | 0,881   | -0,368 | X200m       | 0,420   | 0,857  |
| X400m       | 0,783   |        | X400m       | 0,557   | 0,552  |
| X800m       | 0,920   | 0,232  | X800m       | 0,845   | 0,432  |
| X1500m      | 0,696   | 0,151  | X1500m      | 0,623   | 0,345  |
| X3000m      | 0,808   | 0,209  | X3000m      | 0,745   | 0,375  |
| Maratona    | 0,821   | 0,169  | Maratona    | 0,729   | 0,414  |

Analisando primeiro o modelo, o sem rotação, não conseguimos encher o motivo para fazer uma análise com dois fatores visto que um fator sozinho explicava 69% da variância dos dados e o segundo fator explicava apenas 5,4%. Olhando a figura 4 também não conseguimos encher motivos para um segundo fator, é notável que as variáveis 1 e 2 estão um pouco mais distantes das outras, porém nada alarmante. Na figura 5 todas as variáveis tem cargas altas próximas de 1, o que apenas favorece a ideia de ter apenas 1 fator.

Entretanto ao olhar na tabela nota-se algo curioso, as duas primeiras variáveis(X100m e X200m) tiveram cargas negativas no segundo fator e a terceira variável(X400m) sem nenhum valor, o que pode ser um indicativo de que uma rotação seja necessária.

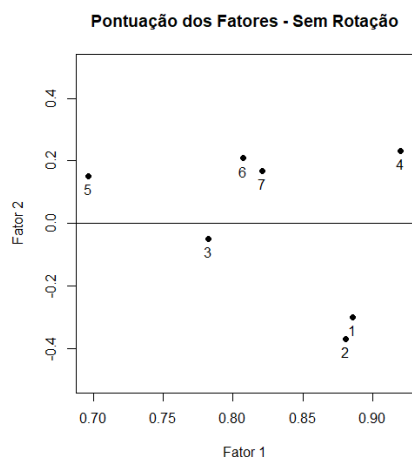


Figura 4: Pontuação dos Fatores - Sem Rotação

Análise Fatorial - Sem Rotação




Figura 5: Fatores - Sem Rotação

Após aplicar a rotação *varimax*, nota-se que o segundo fator começa a fazer sentido, tanto na tabela quanto nos gráficos. As variáveis 1 e 2 tem cargas altas no segundo fator e baixas no primeiro, porém a variável 3 teve carga muito parecida em ambos os fatores, sendo suavemente maior no primeiro fator. Sendo assim, com essa rotação temos uma outra interpretação dos dados porém como citado sobre a variável 3 talvez outro tipo de rotação seja melhor para interpretação dos fatores latentes.

Nas figuras conseguimos visualizar melhor quais variáveis pertencem a quais fatores, na figura 6 conseguimos ver 2 grupos bem claros, apenas com a variável 3 um pouco distante das outras componentes de seu grupo.




Figura 6: Pontuação dos Fatores - Com Rotação

**Análise Fatorial - Com Rotação**

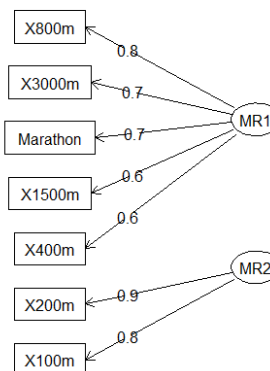


Figura 7: Fatores - Com Rotação

### 5.3 Conclusão Prática

Após a aplicação do método, nos dois modelos diferentes conseguimos ver a importância da rotação na interpretação. No modelo sem rotação temos que apenas um fator é necessário, ou seja apenas uma variável latente, o que é complicado formular alguma hipótese sobre o que seria essa variável latente.

Entretanto, quando rotacionamos os dados, encontramos dois fatores explicados pelos dados. O primeiro fator tem relação com as provas mais longas, como a maratona e prova de 3000 metros, sendo assim podemos dizer que o fator seria a resistência das atletas. Já o segundo fator tem relação só com as duas provas mais curtas, sendo assim poderíamos dizer que a variável latente em questão é a "explosão". Essas hipóteses vem ao pensar que provas mais longas requerem maior resistência(aguentar correr naquela velocidade por mais tempo) enquanto provas mais curtas requerem uma explosão de velocidade maior e mais atenção aos segundos que demora para concluir a prova.

## 6 Conclusão

O método de análise fatorial exploratória se mostrou um ótimo método de redução de dimensionalidade e formulação de hipóteses. Infelizmente não é perfeito, tem como principal desvantagem a necessidade de uma grande amostra ou banco de dados, pois a quantidade de dados é proporcional a quantidade de variáveis. Entretanto tem grande vantagem por manter a representatividade dessas variáveis no método. A interpretação é um ponto que pode ser tanto positivo, por sua facilidade, quanto negativo, por sua subjetividade.

Quanto ao exemplo prático, podemos concluir que é um método bem simples de ser implementado, com poucas linhas de código e muita interpretação gráfica. Tem dois tipos de testes que indicam se é uma abordagem apropriada ou não, e testes bem simples de compreender. Podemos notar o impacto que a rotação tem na interpretação da conclusão ou formulação de hipóteses e ainda podemos ver como a visualização gráfica é benéfica para poucos fatores.

## 7 Referências Bibliográficas

- [1] Johnson, R. A. e Wichern, D. W. (2007). Applied Multivariate Statistical Analysis. Sexta Edição, Prentice Hall, Nova Jersey.
- [2] Matos, D. A. S. e Rodrigues, E. C. (2019). Análise Fatorial. Primeira Edição, Enap, Brasília.
- [3] Frost, J. (2022). Factor Analysis Guide with an Example. [Link](#) (Acessado em 17/09/2023).
- [4] Härdle, W. K. e Simar, L. (2019). Applied Multivariate Statistical Analysis. Quinta Edição, Springer Nature.